

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ
FACULTAD DE CIENCIAS E INGENIERÍA



PUCP

FUNDAMENTOS Y APLICACIONES DE BIOMECATRÓNICA

1MTR58 – 09M1

Tarea Académica

MÓDULO: Procesamiento de Bioseñales en Proyectos Mecatrónicos

TEMA: Reconocimiento de patrones de señales:

Electromiografía (EMG)

Integrantes:

20152418 - Martín Diego Rojas Baes

20201296 - Jorge Eduardo Sialer Kanamori

Profesor: David Achancaray, Ph.D.

Semestre 2024-2

Lima, Perú

1. Resultados


1. Análisis Exploratorio del Dataset EMG

Para empezar el análisis de los datos se extrae los datos de los archivos csv proporcionados, a continuación en la Figura 1 se muestran los datos separados por canales y con su target correspondiente.


	channel_1	channel_2	channel_3	channel_4	channel_5	channel_6	label
0	-0.003949	-0.003949	-0.004100	0.000947	0.000786	0.001108	0
1	-0.003788	-0.002206	-0.002055	-0.009943	-0.007737	-0.007737	0
2	0.002055	0.001894	0.002206	-0.001894	-0.002055	-0.002841	2
3	0.000313	0.000313	0.000000	-0.022254	-0.015312	0.001581	1
4	0.000634	-0.000473	-0.000161	-0.003314	0.000000	0.000161	1
5	-0.000161	0.000634	-0.003153	0.013570	0.008684	0.012623	1
6	0.000000	-0.000634	-0.000473	0.000161	0.000313	0.000634	2
7	-0.128002	-0.146941	-0.238002	0.002680	0.011364	0.011676	2
8	0.018305	0.017992	0.011676	0.026354	0.020994	0.020672	2
9	0.002841	0.003002	0.002528	-0.002680	0.010104	0.010578	2
10	-0.008996	0.008684	0.009309	-0.008049	-0.008523	-0.006629	1
11	0.022254	0.027462	0.027301	0.002367	0.002528	0.001108	2
12	0.001108	0.001733	0.001733	0.005521	0.005521	0.006629	2
13	-0.029195	-0.028409	-0.009470	-0.006468	-0.006941	-0.013570	2
14	-0.015152	-0.004422	-0.022254	0.000947	0.000947	-0.000161	1
15	0.027936	0.040407	0.040881	0.074811	0.077178	0.108902	2
16	0.000473	0.000313	0.000786	-0.001259	-0.000786	-0.000947	0
17	0.002055	0.003314	0.003002	-0.000473	0.000161	0.000000	1
18	-0.000313	-0.000161	0.002841	0.003314	-0.007102	-0.008362	1
19	-0.001733	-0.004261	-0.004100	-0.108116	-0.054924	-0.051771	2
20	0.002206	0.002367	0.000947	-0.001259	-0.000786	-0.000947	2
21	-0.004422	-0.004261	-0.004574	0.001420	0.000786	0.001259	1

Figura 1: Datos del EMG del archivo test.

Para verificar el comportamiento de las señales se presenta una gráfica de amplitud para cada canal, en la Figura 2 se muestra la gráfica para de dataset de entrenamiento.



Además, en la Figura 3, se presenta la matriz de correlación de canales del dataset de entrenamiento, lo cual indica una fuerte relación entre algunos canales del dataset, por ejemplo channel_1 y channel_2.



2. Limpieza y Preprocesamiento de los datos

Al verificar los valores nulos y duplicados dentro del dataset, no se encontró alguno, como se puede ver en la Figura 4




Figura 4: Valores nulos y filas duplicadas en los dataset.

3. Extracción de Características

Como se está analizando un EMG, se extrajeron las características en las ventana de tiempo de los canales, tales como el MAV, RMS, Waveform length y la desviación estándar. Parte de esta extracción se puede observar en la Figura 6.




Figura 5: Parte de las características del dataset.

En cuanto a la normalización de los datos, se empleó el método de z-score ya que es el que presentaba datos más diversos, el dataset normalizado se muestra en la Figura 5.

	MAV	RMS	WL	StdDev	Label
0	-0.640333	-0.610778	-0.514076	-0.579503	2.0
1	-0.562123	-0.517237	-0.475727	-0.519486	1.0
2	-0.455599	-0.387263	-0.309643	-0.362545	1.0
3	-0.316763	-0.376866	-0.141686	-0.291386	1.0
4	-0.537462	-0.513492	-0.403498	-0.540449	0.0
	MAV	RMS	WL	StdDev	Label
0	-0.466736	-0.454018	-0.457412	-0.394460	0.0
1	-0.283674	-0.300616	-0.354729	-0.358984	0.0
2	-0.485349	-0.486382	-0.460102	-0.413161	2.0
3	-0.221691	-0.091333	0.222920	0.039125	1.0
4	-0.565945	-0.521466	-0.417858	-0.469187	1.0
	MAV	RMS	WL	StdDev	Label
0	-0.497234	-0.520433	-0.685589	-0.625540	0.0
1	-0.614774	-0.607356	-0.685140	-0.541484	0.0
2	0.699908	1.120267	3.297915	1.709074	2.0
3	-0.280641	-0.361774	-0.408386	-0.150083	2.0
4	0.040718	0.095185	-0.075023	0.129752	2.0

Figura 6: Dataset de entrenamiento normalizado.

4. Entrenamiento de Modelo

Para el entrenamiento de los se empleó los modelos de random forest, Support Vector Machine y Multilayer Perceptron, de los cuales, como se puede observar en la Figura 7 se tienen las métricas de entrenamiento de los modelos, para este caso se empleó como métrica determinante el F1 score porque es el que captura un equilibrio entre evitar falsos positivos y falsos negativos, lo cual es conveniente para el análisis de EMG.

Resultados del conjunto de test:				
	Accuracy	F1-Score	Precision	Recall
Random Forest	0.731707	0.712195	0.694541	0.731707
Support Vector Machine	0.463415	0.501425	0.790373	0.463415
Multilayer Perceptron	0.756098	0.709904	0.677927	0.756098

Figura 7: Resultados del entrenamiento de los modelos.

Se puede observar en la Figura 8 el resultado del pase de la data de validación por los 3 modelos entrenados.

Resultados del conjunto de validación:				
	Accuracy	F1-Score	Precision	Recall
Random Forest	0.512195	0.517683	0.526744	0.512195
Support Vector Machine	0.463415	0.471065	0.663618	0.463415
Multilayer Perceptron	0.560976	0.551515	0.554878	0.560976

Figura 8: Resultados del conjunto de validación.

5. Gráficas de métricas de rendimiento del Modelo (4 puntos)

En la Figura 9, 10 y 11 se puede observar las matrices de confusión de los modelos entrenados. Se puede observar que los modelos Random Forest y MLP tienen una buena tasa de predicción con respecto a los dos últimos movimientos, sin embargo para el primer movimiento no predice adecuadamente, esto puede ser debido a la poca cantidad de muestras con este tipo de movimiento en el dataframe del entrenamiento. Por otro lado, para el SVM si logra capturar correctamente este primer movimiento, pero para los otros dos movimientos comete muchas fallas.

Evaluando modelo: Random Forest en el conjunto de test

Matriz de Confusión - Test (Random Forest)




Figura 9: Matriz de confusión de Random Forest en el conjunto de test

Evaluando modelo: Support Vector Machine en el conjunto de test

Matriz de Confusión - Test (Support Vector Machine)




Figura 10: Matriz de confusión de Support Vector Machine en el conjunto de test

Evaluando modelo: Multilayer Perceptron en el conjunto de test

Matriz de Confusión - Test (Multilayer Perceptron)




Figura 11: Matriz de confusión de Multilayer Perceptron en el conjunto de test

En la Figura 12 se puede observar la matriz de confusión de la data de validación al ser sometida al modelo en el cual presentó mejor desempeño en cuanto a su valor de F1-score.

Evaluando modelo: Multilayer Perceptron en el conjunto de validación

Matriz de Confusión - Validación (Multilayer Perceptron)




Figura 12: Matriz de confusión de Multilayer Perceptron en el conjunto de validación

2. Conclusiones y observaciones:

1. Conclusiones

- El MLP logra el mejor equilibrio con un F1-Score de 0.7099 en test y 0.5515 en validación. Esto demuestra que es el modelo más robusto y capaz de generalizar, aunque su desempeño disminuye en la validación debido a las diferencias en la distribución de los datos.
- El Random Forest presenta un buen F1-Score en test (0.7122), pero cae significativamente en validación (0.5177). Esto indica que el modelo se adapta bien a datos similares a los de entrenamiento, pero tiene dificultades para generalizar a datos diferentes, como los movimientos específicos del conjunto de validación.
- Todos los modelos muestran una caída en el F1-Score al pasar de test a validación. Esto refleja las diferencias en la distribución de datos del conjunto de validación.

2. Observaciones: Considere en observaciones las dificultades que tuvieron durante la experiencia

- Se podría considerar el uso de data más grande para la TA y así tener un mejor entrenamiento.
- Se podría haber dado un contexto de la data que se capturó con el EMG como la cantidad de personas evaluadas o movimientos realizados.